




Universidade Estadual de Campinas
Instituto de Computação



MO434 - Deep Learning

Identificação: Christian Massao Konishi – RA 214570

Resumo

Inserir resumo

1 Exercício 1 – Exemplo de uma primeira rede neural para imagens

- Notebook: *first-image-neuralnet.ipynb*

1.1 Descrição

O notebook consiste na implementação simples de uma rede neural, seu treinamento e avaliação sobre a base de dados Fashion-MNIST[1]. A base de dados consiste em 60.000 imagens em escala de cinza de 28x28 pixels, que foram divididos em conjunto de treinamento, validação e teste, com tamanhos de 30.000, 15.000 e 15.000, respectivamente.

A rede neural proposta no enunciado em 3 camadas densamente conectadas com inicialização de Xavier, com função de ativação ReLU e operação de Dropout com probabilidade de 25%. A função de custo utilizada é a entropia cruzada, com otimizador Adam e taxa de aprendizado 10^{-5} .

Depois de 40 épocas de treinamento, o gráfico de treinamento (Figura 1) indicou que houve um *underfitting*, caracterizado pelo custo de validação menor do que o de treinamento. A acurácia obtida no teste foi de 0,85.




Figura 1: Gráfico do custo de treinamento e de validação ao longo das épocas de treinamento.

O exercício proposto envolve a modificação do modelo e dos processos de treinamento de forma a solucionar o problema encontrado, mas sem causar *overfitting*.

1.2 Solução do Exercício Proposto

Diferentes abordagens para reduzir o fenômeno de *underfitting* podem ser aplicadas, entre elas o aumento da taxa de aprendizado ou o aumento de épocas, aumentar a complexidade da rede neural, aumentando a quantidade de camadas escondidas, por exemplo, entre outras possibilidades. Outra possibilidade seria a redução da probabilidade associada à operação de *dropout*, que poderia estar

exagerada, prejudicando a rede – apesar de que o valor de 0,25 não é considerado elevado, então é improvável que isso seja um problema.

A primeira alteração feita foi adicionar uma camada escondida extra, entre a segunda e terceira, com entrada de 200 *features* e saída de 100, fazendo-se as alterações necessárias na primeira camada densamente conectada para encaixá-la. A acurácia final não sofreu alteração significativa, nesse sentido, a mudança poderia ter sido descartada, mas para fins de estudo, ela foi mantida.

A segunda mudança foi aumentar a taxa de aprendizado, visto que observando a Figura 1, a rede ainda parecia estar convergindo ao fim do treinamento. Aumentar a taxa para 10^{-4} demonstrou-se exagerado, visto que houve um *overfitting* do modelo, caracterizado pelo função de custo de treinamento, que continuou a reduzir, mesmo com a estabilidade do custo de validação (Figura 2). É possível que com mais épocas, o custo de validação chegasse até mesmo a aumentar.




Figura 2: Gráfico do custo de treinamento e de validação ao longo das épocas de treinamento para uma taxa de aprendizado de 10^{-4} .

2 Exercício 2 – Introdução ao Pytorch Convnet

- Notebook: *introducing-pytorch-convnet.ipynb*

2.1 Descrição

O notebook em questão contém uma série de demonstrações de conceitos básicos do Pytorch, como as operações de convolução, a função de ativação, *pooling*. Além de *skip connections*, camadas densamente conectadas, *dropout* etc. Por fim, há um processo de construção e treinamento de uma rede neural, desde sua construção, definição de função de perda e otimizador, processo de treinamento e validação.

O problema do processo que foi realizado é que houve *overfitting*. O exercício em questão consiste numa exploração dos elementos e hiperparâmetros utilizados para melhorar o resultado obtido

2.2 Conceitos

Referências

- [1] H. Xiao, K. Rasul, and R. Vollgraf. (2017) Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms.